

Merit-Ending

데이터분석/데이터 분석 및 시각화

[데이터 분석 및 시각화] 3. 단변량 분석 - 수치형

엔딩o 2025. 4. 1. 22:58 (⋮)

수치형 변수란 비교할 수 있는 연속적인 숫자를 갖는 변수!

평균, 최댓값, 최솟값, 중앙값 등을 확인해 분석

쉽게 이해하려면 데이터의 평균을 낼 수 있냐? 속으로 생각하면 된다.

데이터 불러오기, 전처리는 생략 => 타이타닉 데이터를 불러왔다.

★ 수치형(양적 데이터)을 수치화하려면 Min, Max, Mean, Std, 사분위수 등의 메서드를 사용한다.

★ 수치형(양적 데이터)을 시각화하려면 Histogram, Density Plot, Box Plot, Linear Plot 등의 시각화 도구를 사용한다.

1. 수치화

수치형 변수를 수치화해 분석할 때는 평균, 중앙값, 최빈값, 4분위수 등 대표값을 사용

1) 평균

mean(): 평균

```
titanic['Fare'].mean()
```

2) 중앙값

median(): 중앙값 => 데이터 크기 순으로 나열 했을 때 가운데 위치한 값

```
titanic['Fare'].median()
```

3) 최빈값

mode(): 빈도가 가장 높은 값

```
titanic['Pclass'].mode()
```

최빈값의 value는 인덱스를 사용해 조회

```
titanic['Pclass'].mode()[0]
```

동일 코드

```
titanic['Pclass'].value_counts().idxmax()
```

4) 4분위수

describe(): 모든 기술통계 조회

Q1: 1사분위수(25%)

Q2: 2사분위수(50%)

Q3: 3사분위수(75%)

Q4: 4사분위수(100%)

```
print('Q1:', titanic['Fare'].describe()['25%'])
print('Q2:', titanic['Fare'].describe()['50%'])
print('Q3:', titanic['Fare'].describe()['75%'])
print('Q4:', titanic['Fare'].describe()['max'])
```

2. 기술통계 정보

describe()

1) Age 대한 기술 통계 정보

```
titanic['Age'].describe()
```

2) 리스트 형태를 데이터프레임 형태로(단, 구글 코랩은 자동으로 바꿔주는 것 같다.)

```
titanic[['Age']].describe()
```

3) 가로, 세로 방향을 바꾸어서 보기쉽게하기

```
titanic[['Age']].describe().T
```

3. 시각화


1) 히스토그램

Histogram: 데이터 분포를 확인하는 가장 기본적인 시각화 도구

- Matplotlib 사용

```
hist()
```


```
plt.hist(x='Fare', data=titanic, ec='k')  
plt.xlabel('Fare')  
plt.ylabel('Frequency')  
plt.show()
```



- Seaborn 사용

```
histplot()
```


```
sns.histplot(x='Fare', data=titanic)  
plt.show()
```



Seaborn이 뭔가 더 세밀하게 보여주는 것 같다

하지만 Matplotlib과 비교하기 위하여 조금 비슷하게 만들어보자
아래 코드와 같이 빈도수를 조절하여 그래프를 표현 할 수 있다.

```
sns.histplot(x='Fare', data=titanic, bins=20)
plt.show()
```



확실히 sns를 사용하는 것이 더 세밀하게 분석가능하다

```
sns.histplot(x='Age', data=titanic)
plt.show()
```


2) Density Plot

Histogram은 bins 옵션에 따라 다양한 모양이 만들어져 데이터를 분석하는데 한계가 분명히 있다. 이러한 문제를 극복하기 위해 Density Plot이 등장하였고 이를 커널밀도추정 방식이라고 한다.

- Pandas 사용


```
plot(kind='kde')
```

```
titanic['Fare'].plot(kind='kde')  
plt.show()
```



- Seaborn 사용

```
sns.kdeplot(x='Fare', data=titanic)  
plt.show()
```



```
sns.kdeplot(x='Age', data=titanic)
plt.show()
```

3) Box Plot

가장 많은 정보를 뽑아낼 수 있는 시각화 도구!!!


평균부터 이상치까지 만능

- Matplotlib 사용

boxplot()

Matplotlib의 한계: 결측치가 있으면 그려지지 않는다.

```
plt.boxplot(x='Fare', data=titanic)
plt.show()
```



※ 해석

박스 플롯을 보면 타이타닉의 운임은 극단적으로 편향된 분포를 보이며, 일부 승객들이 매우 높은 운임을 지불했다. => 이상치


대부분의 승객은 저렴한 가격 3등석(Pclass=3)을 지불한 것으로 추측된다.

1등석과 3등석의 운임 차이가 매우 크다는 점을 시각적으로 확인할 수 있다. 이상치를 보면, 가장 높은 운임을 지불한 승객이 500 이상의 값을 기록했는데, 이는 당시 1등석의 고급 객실을 의미할 가능성이 높다.

- Seaborn 사용

boxplot()

```
sns.boxplot(x='Fare', data=titanic)
plt.show()
```



Seaborn은 결측치가 있어도 그려지는 똑똑한 도구~

세로 방향으로 표시하고 싶으면 'y=?' 꼴로 선언하면 된다.

```
sns.boxplot(y='Age', data=titanic)
plt.show()
```

4) Line plot - 시계열 데이터 시각화


- Matplotlib 사용

plot(): Line plot 그릴 수 있다.

시열 데이터는 보통 시간 축(x축)에 맞게 값들을 선 그래프로 표현합니다.

```
air['Date'] = pd.to_datetime(air['Date'])
```

```
plt.plot('Date', 'Ozone', data=air, label='Ozone')
plt.plot('Date', 'Temp', data=air, label='Temp')
plt.xlabel('Date')
plt.legend()
plt.show()
```





날짜에 따른 오존 농도

- Seaborn 사용


lineplot(): Line Plot 그리기

```
sns.lineplot(x='Date', y='Ozone', data=air, label='Ozone')
sns.lineplot(x='Date', y='Temp', data=air, label='Temp')
plt.legend()
plt.show()
```



LinePlot은 많이 쓰이지는 않지만 순환신경망(RNN)에서 많이 쓰일 것 같다. Matplotlib과 Seaborn의 차이도 많이 나지않는다.

4. 박스 플롯의 의미



- 박스플롯(Box Plot)은 데이터의 분포, 중앙값, 이상치를 시각적으로 표현하는 그래프이다.
- 박스플롯은 최솟값, 1사분위수(Q1), 중앙값(중위수), 3사분위수(Q3), 최댓값으로 구성된다.
- 수염(Whiskers)은 일반적인 데이터 범위를 나타내며, 그 바깥에 있는 점들은 이상치(Outliers)이다.
- 이상치는 $Q1 - 1.5 \times IQR$ 이하 또는 $Q3 + 1.5 \times IQR$ 이상인 값들로 정의된다.
- 데이터가 한쪽으로 치우쳤는지(왜곡 여부)를 확인하는 데 유용하다.
- 타이타닉 운임(Fare) 박스플롯에서는 일부 승객이 500 이상의 운임을 지불한 것이 이상치로 나타난다.
- 박스플롯은 성별, 직업군, 지역별 차이 등 데이터를 비교 분석하는 데 효과적이다.
- Python의 seaborn 라이브러리를 사용하면 `sns.boxplot()`을 통해 쉽게 박스플롯을 그릴 수 있다.
- 박스플롯의 장점은 이상치를 쉽게 찾을 수 있고 데이터의 분포를 빠르게 파악할 수 있다는 점이다.
- 박스플롯은 시험 점수, 급여 비교, 병원 데이터 분석, 주식 변동성 분석 등 다양한 분야에서 활용된다.


한마디로 표현하면 데이터의 분포가 어디에 쏠려있는지 한 눈에 파악 가능하고, 더불어 평균, 중앙값, 사분위수, IQR 값을 빠르게 파악 할 수 있으며 이 범위(IQR)에 크게 벗어나면 이상치라고 판단할 수 있는 그래프이다.

히스토그램과 함께 쓰면 더 데이터를 쉽게 파악할 수있고 히스토그램보다 얻을 수 있는 정보가 더 많은 것을 확인할 수 있음

```
plt.figure(figsize=(8, 5))
plt.subplot(2, 1, 1)
sns.histplot(x='Age', bins=20, data=titanic)
```

```
plt.subplot(2, 1, 2)
sns.boxplot(x='Age', data=titanic, color='w', medianprops={'color': 'tab:orange'})

plt.tight_layout()
plt.show()
```



히스토그램과 박스 플롯

공감


데이터분석 > 데이터 분석 및 시각화 카테고리의 다른 글

[데이터 분석 및 시각화] 2. 시각화(Seaborn 활용) (0)

2025.04.04

[데이터 분석 및 시각화] 1. 시각화(Matplotlib 활용) (0)

2025.04.04

'데이터분석/데이터 분석 및 시각화' Related Articles

선 스타일, 마커 형태			선 색상		
vector	description	character	description	character color	
	solid line style	'r'	tri_right marker	'b'	blue
	dashed line style	'v'	square marker	'g'	green
	dash-dot line style	'p'	pentagon marker	'r'	red
	dotted line style	'^'	star marker	'c'	cyan
	point marker	'h'	hexagon1 marker	'm'	magenta
	pivel marker	'H'	hexagon2 marker	'y'	yellow
	circle marker	'x'	plus marker	'k'	black
	triangle_down marker	'X'	x marker	'w'	white
	triangle_up marker	'D'	diamond marker		
	triangle_left marker	'd'	thin_diamond marker		
	triangle_right marker	'T'	vine marker		
	tri_down marker	'*'	hline marker		
	tri_up marker				
	tri_left marker				

[데이터 분석 및 시각화] 2.
시각화(Seaborn 활용)

[데이터 분석 및 시각화] 1.
시각화(Matplotlib 활용)

Merit-Ending

엔딩o 님의 블로그입니다.

댓글 0



엔딩o

내용을 입력하세요.

등록

DESIGN BY TISTORY 관리자