

Merit-Ending

데이터분석/데이터 분석 및 시각화

[데이터 분석 및 시각화] 2. 시각화(Seaborn 활용)

엔딩o 2025. 4. 4. 21:36

Seaborn은 Matplotlib 기반으로 작성된 고수준 인터페이스 시각화 도구
Matplotlib보다 훨씬 다양한 스타일 테마를 지원
Matplotlib 보다 좋다는 말은 아니다!

데이터 읽어오기, 전처리 과정 생략~ 타이타닉 데이터 실습이다.

1. 기본 그래프

1) Histogram


histplot(): 단일 변수의 데이터 분포를 히스토그램으로 표시 => 빈도수 표시로 이해

Age 열의 분포를 확인 => 20대는 몇명?, 30대는 몇명?, 70대는 몇명?

```
sns.histplot(x='Age', data=titanic, bins=16, ec='k')  
plt.show()
```

Age 열 분포에 Survived라는 열을 hue로 설정해주면 나이 별로 생존자를 표시해준다.

```
sns.histplot(x='Age', hue='Survived', data=titanic, bins=16, ec='k')  
plt.show()
```



생존자는 1 사망자는 0으로

육안으로 봤을 때 0~5세 사이의 생존자가 사망자에 비해 많은 것으로 확인 할 수 있고

주로 20~30대의 생존자도 조금 있는 것 같지만 사망자가 훨씬 많으므로 생존자가 많다고 1차원적으로 단정지어서는 안된다.

2) Density Plot

kdeplot(): 커널밀도함수 그래프로 숫자형 변수의 값 분포를 확인 할 수 있다.

Age 변수의 데이터 분포를 Density Plot으로 확인


```
sns.kdeplot(x='Age', data=titanic)
plt.show()
```

Age 변수의 데이터 분포를 Survived 열을 기준으로 구분

common_norm=False를 지정하면 그래프 각각의 면적이 1이된다.

```
sns.kdeplot(x='Age', hue='Survived', data=titanic, common_norm=False)
```


```
plt.show()
```



이렇게 할 경우에 생존자와 사망자 둘 차이가 없어보인다.

`common_norm=True`를 지정하면 두 그래프 면적의 합이 1이 된다.

```
sns.kdeplot(x='Age', hue='Survived', data=titanic, common_norm=True)  
plt.show()
```



이렇게 생존자의 수, 사망자의 수를 더한 면적 값을 1로 제한해놔야지 어떤 개체가 빈도수가 많은지 비율적으로 접근할 수 있게된다.

3) Box Plot

boxplot() 함수는 주식을 생각하면 된다!

단일 변수나 여러 변수의 분포와 이상치를 한 눈에 확인 할 수 있다.


박스권이라고 하고 이를 벗어날 경우에 이상하다고 판단하여 이상치라고 부른다

1) 단일 변수

```
sns.boxplot(y='Age', data=titanic)
plt.show()
```

2) 여러 변수

```
sns.boxplot(y='Age', x='Survived', data=titanic)
plt.show()
```




이런식으로 Age 별 생존자 분포를 확인 할 수 있고 사분위수, 평균, 중위값, 이상치같은 정보들을 많이 뽑아낼 수 있다.

3) 가로 형태로 보기

```
sns.boxplot(x='Age', data=titanic)
plt.show()
```

단, 여러 변수를 입력하여 가로 형태로 볼 경우 구분 기준 orient='h'를 지정해줘야됨

```
sns.boxplot(x='Age', y='Survived', data=titanic, orient='h')
plt.show()
```



2. 고급 그래프

시본의 매력을 느낄 차례이다.

1) Distribution Plot

`distplot()`: 단일 변수의 분포를 시각화 하기 위한 함수

Histogram과 Density Plot을 같이 표시 가능

`hist_kws` 매개변수에 꾸미기 위한 다양한 설정 값을 딕셔너리 형태로 전달

Age 열의 `distplot`

```
sns.distplot(x=titanic['Age'], bins=16, hist_kws={'ec': 'k'})
plt.show()
```

2) Joint Plot


`jointplot()`: 두 변수 간의 관계를 시각화하기 위해 산점도와 히스토그램을 함께 그리기

꽃잎의 길이와 꽃잎의 가로길이의 관계는 어떻게될까?

```
sns.jointplot(x='Petal.Length', y='Petal.Width', data=iris)
plt.show()
```

Species가 3개 이상이면 Matplotlib에서 표현하기 힘든 그래프를 Seaborn에서는 간편하게 표현가능
hue 매개변수에 범주형 변수를 지정해 색깔을 구분

```
sns.jointplot(x='Petal.Length', y='Petal.Width', data=iris, hue='Species')
plt.show()
```



3) Pair Plot

`pairplot()`: 변수 간의 산점도 및 변수 분포를 한 번에 시각화하는 기능

=> 데이터의 모든 경우의 수를 다 그래프로 표현하는 것

※ 시간많이 걸림


```
sns.pairplot(iris, hue='Species')  
plt.show()
```

4) Count Plot

countplot(): 범주형 변수의 빈도를 막대 그래프로 시각화

Embarked 변수의 범주값이 몇 개씩 표현되어 있는지


```
sns.countplot(x='Embarked', data=titanic)  
plt.show()
```



Southampton > Cherbourg > Queenstown 순으로 많이 탑승하였다.

hue 옵션을 주어 생존여부를 범주형 막대그래프 옆에 표시해보자

```
sns.countplot(x='Embarked', hue='Survived', data=titanic)  
plt.show()
```


사우스햄튼에서 많이 타고 많이 사망하였고
프랑스에서 그 다음으로 탔지만 사망자보다 생존자는 많아 보인다.

5) Bar Plot

`barplot()`: 범주형 변수에 막대 그래프를 그린다.

데이터를 추정하고 오차 막대를 표시할 수 있는데, 이 오차 막대는 각 범주의 평균과 신뢰구간을 시각화하는 데 사용된다.

```
sns.barplot(x='Embarked', y='Fare', data=titanic)
plt.show()
```



프랑스에서 평균적으로 요금을 많이 냈고 사망자 수가 많았던 사우스햄톤에서는 평균적으로 요금을 적게 낸 것으로 보인다.

이런식으로 신뢰구간을 설정할 수 있다.

```
sns.barplot(x='Embarked', y='Fare', data=titanic, estimator=np.mean, errorbar=('ci', 95))
plt.show()
```

6) HeatMap

heatmap() 함수는 두 범주형 변수를 집계한 결과를 색의 농도 차이로 표시
그래프를 만들기전에 Groupby와 Pivot을 설정 해줘야된다.

Embarked 별 Pclass 별 탑승자 수를 표시하고 이를 색 농도로 나타내

```
temp1 = titanic.groupby(['Embarked', 'Pclass', as_index=False])['PassengerId'].count()
temp2 = temp1.pivot(index='Embarked', columns='Pclass', values='PassengerId')
display(temp2)
```

```
sns.heatmap(temp2, annot=True)
plt.show()
```

표시되는 값을 정수로, 구간 간격을 조금 벌리고, 색상도 예쁘게 꾸미자

```
sns.heatmap(temp2, annot=True, fmt='d', linewidth=2, cmap='Blues')
plt.show()
```

공감

구독하기

'데이터분석' > '데이터 분석 및 시각화' 카테고리의 다른 글

[데이터 분석 및 시각화] 1. 시각화(Matplotlib 활용) (0)

2025.04.04

[데이터 분석 및 시각화] 3. 단변량 분석 - 수치형 (0)

2025.04.01

'데이터분석/데이터 분석 및 시각화' Related Articles

선 스타일, 마커 형태			선 색상	
vector	description	character	description	character
	solid line style	'-'	tri_right marker	'>'
	dashed line style	'--'	square marker	'v'
	dash-dot line style	'-.'	pentagon marker	'^'
	dotted line style	'....'	star marker	'x'
	point marker	'.'	hexagon1 marker	'm'
	pixel marker	'H'	hexagon2 marker	'y'
	circle marker	'o'	plus marker	'k'
	triangle_down marker	'v'	x marker	'w'
	triangle_up marker	'^'	diamond marker	
	triangle_left marker	'<'	thin_diamond marker	
	triangle_right marker	'>'	vline marker	
	tri_down marker	'v'	hline marker	
	tri_up marker	'^'		
	tri_left marker	'<'		

NO IMAGE

[데이터 분석 및 시각화] 1.
시각화(Matplotlib 활용)

[데이터 분석 및 시각화] 3.
단변량 분석 - 수치형

Merit-Ending

엔딩o 님의 블로그입니다.

구독하기

댓글 0

이름

비밀번호

내용을 입력하세요.

등록

