



endingo

정훈이의 공부일지

CATEGORY



👋 안녕하세요, AI 개발자 이정훈입니다

AI · 백엔드 · 데이터 분석 중심의 프로젝트와 경험을 공유합니다.

 Contact Me

Data analysis/데이터 분석 및 시각화

[데이터 분석 및 시각화] 6. 이변량분석 - (범주형 -> 수치형)

endingo 2025. 4. 5. 11:14

범주형 -> 수치형 그래프를 나타내려면 어떤 도구를 사용할까?

★ 범주형 -> 수치형 시각화 도구 barplot(), boxplot()

데이터 불러오기 전처리 과정은 타이타닉으로 했다.

1. 시각화


- Seaborn 사용

1) barplot(): 범주값의 평균을 비교 할 수 있다.

```
sns.barplot(x='Survived', y='Age', data=titanic)
plt.show()
```



정훈이의 공부일지




생존자와 사망자 각각의 나이 평균을 볼 수 있는 것

사망자: 31세

생존자: 28세

2) boxplot(): 범주값 간의 값 분포를 비교

```
sns.boxplot(x='Survived', y='Age', data=titanic)
plt.show()
```



생존자 사망자 각각의 평균, 중앙값, 사분위수, 이상치 판단을 할 수 있다.

생존자 중앙값: 29

사망자 중앙값: 28

생존자 이상치: 81세, 61세~62세




정훈이의 공부일지



2세~3세 정도 차이가 있음

3) 등석 별 나이의 차이

```
plt.figure(figsize=(8, 3))
plt.subplot(1, 2, 1)
sns.barplot(x='Pclass', y='Age', data=titanic)
plt.subplot(1, 2, 2)
sns.boxplot(x='Pclass', y='Age', data=titanic)
plt.tight_layout()
plt.show()
```



객석 등석 별(범주형) 나이(수치형) 평균에 차이가 있나?

조금 있다. $1 > 2 > 3$

1 클래스인 사람들의 나이가 다른 집단에 비해 많은 것으로 보아

'Fare': 나이가 들수록 돈이 많으니까 1등석을 예약한 것으로 예측된다.

2. 수치화

범주형 -> 수치형 데이터의 수치화는 t-검정, ANOVA를 사용한다.

이것을 하기위해서 결측치가 있으면 안된다.

1) t-검정

두 집단의 평균값이 서로 유의하게 다른지 검정하는 통계적인 방법

- scipy.stats 라이브러리 사용

ttest_ind(): t-검정 수행

※ t-statistics, t-value, t-통계량

두 평균의 차이를 표준오차로 나눈 값으로 두 평균의 차이



정훈이의 공부일지



※ p-value

t-검정에서 p-value는 유의확률

귀무가설 대립가설 설명할 때 나왔던 개념으로 p-value 값이 0.05 보다 작으면 대립가설이 채택되고 귀무가설이 기각된다.

=> p-value 값이 작으면 통계적으로 유의미한 차이가 있다는 것

※ 표준오차

- 모집단의 평균을 구하고 싶지만, 모집단이 너무커서 구할 수 없을때, 우리는 표본을 뽑아 표본의 평균을 구한다.
- 계속 표본을 뽑아 평균을 구하는 작업을 반복한다
- 이 표본들의 평균들을 모두 더해서 평균을 취하면 표본들의 평균의 평균이 나온다.(말이 어렵다!!!)
- 이 표본들의 평균의 표준편차를 표준오차라고 부른다.

☆ 수식으로 한번 나타내보자

모집단에서 표본을 뽑아 만든 표본들의 평균을 m_n (n 은 자연수)이라고 하자

한 번 반복하면

=> m_1

열 번 반복하면

=> $m_1, m_2, m_3, \dots, m_{10}$ 의 값들이 나온다.

이 표본들의 평균을 구하자

=> $m_1 + m_2 + m_3 \dots + m_{10} / 10$

이 표본들의 표준편차를 구하자

=> 표준오차

임의의 두 개의 모집단 만들기

pop1: 평균이 160, 표준편차가 10인 100,000개의 실수

pop2: 평균이 170, 표준편차가 10인 100,000개의 실수

```
pop1 = [round(rd.normalvariate(160, 10), 1) for i in range(100000)]
```

```
pop2 = [round(rd.normalvariate(170, 10), 1) for i in range(100000)]
```

확인

```
print('* pop1:', pop1[:10])
```

```
print('* pop2:', pop2[:10])
```


이렇게 두 개의 모집단이 만들어 졌다. 그래프로 확인해보자

```
plt.figure(figsize=(8, 5))
```

```
sns.kdeplot(pop1)
```



정훈이의 공부일지



모집단일 경우 이렇게 차이가 난다. 시각화하는 것은 간단해보이지만 수치화하는 것은 생각보다 많은 계산이 들어갈 수 있다.

그렇기에 위 모집단에서 표준을 뽑아서 t-검정으로 수치화 해보자

먼저 pop1 모집단에서 s1 표준집단, s2 표준집단을 뽑아낸다.

```
s1 = rd.sample(pop1, 200)
s2 = rd.sample(pop1, 200)
t_test = spst.ttest_ind(s1, s2)
```

```
print('* t-statistic:', t_test[0])
print('* p-value:', t_test[1])
```

```
* t-statistic: 1.6474170639362318
* p-value: 0.10026158386443014
```

t-통계량이: 2보다 작은 것을 확인할 수 있다.

=> 차이가 없다는 것이다.

p-value: 0.05보다 크다

=> 대립가설 기각 의미있는 차이가 없다.(귀무가설 채택)

이처럼

t-통계량, p-value에서 pop1 모집단에서 뽑은 표준들은 별로 차이가 없다는 사실을 확인 할 수 있다.

당연하다!!!! 왜냐하면 같은 모집단에서 표준 2개를 뽑은 것이니



정훈이의 공부일지



```
s1 = rd.sample(pop1, 200)
s2 = rd.sample(pop2, 200)
t_test = spst.ttest_ind(s1, s2)
```

```
print('* t-statistic:', t_test[0])
print('* p-value:', t_test[1])
```

```
* t-statistic: -11.023147471057493
* p-value: 7.714536102110736e-25
```

t-통계량: -2보다 훨씬 작다. => 차이가 있다!

p-value: 0.05보다 훨씬 작다 => 차이가 있다!(대립가설 채택)

- titanic 데이터 프레임 시도

Survived(범주형)-> Age(수치형) 생존 여부별로 나이에 차이가 있냐?

먼저 결측치 여부를 확인한다.

```
titanic.isna().sum()
```

	0
PassengerId	0
Survived	0
Pclass	0
Name	0
Sex	0
Age	177
SibSp	0
Parch	0
Ticket	0
Fare	0
Cabin	687
Embarked	2

실습하려는 Age가 이질적이다. 이는 결측치가 있다고 판단할 수 있다.

Age의 결측치가없는 행만가져와 사망자들의 나이와 생존자들의 나이를 구하고 t-검정해본다.

```
temp = titanic.loc[titanic['Age'].notnull()]
died = temp.loc[temp['Survived']==0, 'Age']
survived = temp.loc[temp['Survived']==1, 'Age']
```



정훈이의 공부일지



```
print(" p-value:", t_test[1])
```

```
* t-statistic: 2.06668694625381
* p-value: 0.03912465401348249
```

t-검정: 2보다 조금 크다! => 조금 차이가 있다!

p-value: 0.05보다 작다! => 조금의 차이지만 유의미한 차이임은 분명(대립가설 채택)

성별별 요금의 차이는 있을까?

남자의 탑승요금 vs 여자의 탑승요금 (Fare는 이질적이지 않으므로 결측치 없음!)

```
male = titanic.loc[titanic['Sex']=='male', 'Fare']
```

```
female = titanic.loc[titanic['Sex']=='female', 'Fare']
```

```
t_test = spst.ttest_ind(male, female)
```

```
print('* t-statistic:', t_test[0])
```

```
print('* p-value:', t_test[1])
```

```
* t-statistic: -5.529140269385719
* p-value: 4.2308678700429995e-08
```

t-통계량: -2보다 확실히 작다 => 유의미한 차이

p-value: 0.05보다 확실히 작다 => 유의미한 차이(대립가설 채택)

남녀별 탑승요금이 다르다!

2) 분산분석

두 개의 집단 간의 범주형 -> 수치형의 수치화는 t-검정을 사용하여 처리했지만

세 개 이상의 집단 간의 차이는 분산분석(ANOVA)로 비교

- scipy.stats 라이브러리 사용

f_oneway(): 기준을 전체 평균으로하고 분산분석

※ f-statistics, f-통계량, f-value

두 개 이상의 집단 간 분산의 비율을 검정하는데 사용되는 통계량

f 통계량은 각 집단이 모집단으로부터 동일한 분산을 가지는지 검증한다.

분산의 비율이 클수록 f-통계량 값이 커진다.



정훈이의 공부일지



$$f - \text{통계량} = \frac{\text{집단간분산}}{\text{집단내분산}}$$

집단내의 분산이 작다는 것은 무슨 뜻일까?

특정 집단에 구성원들끼리 똘똘 뭉친것이다. => 그러면 다른 집단간의 차이가 확실히 날 수 밖에없다.

집단간 분산이 크다는 것은 무슨 뜻일까?

특정 집단군과 다른 집단군과 멀리 떨어져있다는 것이다. => 다른 집단간의 차이가 확실히 날 수 밖에없다.

f-통계량이 크려면?


집단 구성원들끼리 똘똘뭉치고, 다른 집단과 사이가 안 좋아야됨!!

=> 집단간의 유의미한 차이

시각화를 먼저해보자

```
print('* 전체평균: {}'.format(titanic['Age'].mean()))
```

```
sns.barplot(x='Pclass', y='Age', data=titanic)
plt.show()
```



범주형 -> 수치형 관점으로 봤을 때

객실 등급별 나이는 시각화로 봤을 때도 확실한 차이가 있어보이긴한다.

f-통계량 확인해보자: 방법은 똑같은데 f_oneway 사용하면됨

```
temp = titanic.loc[titanic['Age'].notnull()]
p1 = temp.loc[temp['Pclass']==1, 'Age']
```




정훈이의 공부일지



```
print("f-statistic:", anova[0])  
print("p-value:", anova[1])
```

```
* f-statistic: 57.443484340676214  
* p-value: 7.487984171959904e-24
```

f-통계량: 57로 엄청크다 => 집단끼리 똥똥똥했다 => 유의미한차이가 분명히 있다.

p-value: 0.05보다 확실히 작다 => 확실히 유의미한 차이가있다(대립가설 채택)

공감

구독하기

[Data analysis](#) > [데이터 분석 및 시각화](#) 카테고리의 다른 글

[\[데이터 분석 및 시각화\] 8. 이변량분석 - \(수치형 -> ...](#) (0)

[\[데이터 분석 및 시각화\] 7. 이변량분석 - \(범주형 -> ...](#) (0)

[\[데이터 분석 및 시각화\] 5. 이변량분석 - \(수치형 -> ...](#) (0)

[\[데이터 분석 및 시각화\] 4. 단변량 분석 - 범주형](#) (0)

[\[데이터 분석 및 시각화\] 2. 시각화\(Seaborn 활용\)](#) (0)

정훈이의 공부일지

개발하면서 겪는 시행착오와 배움을 기록합니다. 백엔드, AI, 데이터 분석, 프로젝트 경험 중심으로 운영 중입니다. 공부하면서 얻은 인사이트를 함께 나누고 싶어요!

구독하기

댓글 0



이름

비밀번호



정훈이의 공부일지



등록

공지사항

최근에 올라온 글

최근에 달린 댓글

Total

93

[딥러닝] 3. 회귀 모델링

[딥러닝] 2. Pytorch

[딥러닝] 1. 딥러닝 개요

[데이터 분석 및 시각화] 8. 이변...

Today

28

Yesterday

25

링크

TAG

[more](#)

« 2025/04 »

글 보관함

github git

일	월	화	수	목	금	토
		1	2	3	4	5
6	7	8	9	10	11	12
13	14	15	16	17	18	19
20	21	22	23	24	25	26
27	28	29	30			

2025/04 (13)

2025/03 (7)

Blog is powered by Tistory / Designed by Tistory



이정훈 개발자

AI와 백엔드, 데이터 분석을 좋아하는 개발자입니다.
다양한 문제 해결과 창의적인 개발을 추구합니다.

이메일 보내기