



endingo

정훈이의 공부일지

CATEGORY



👋 안녕하세요, AI 개발자 이정훈입니다

AI · 백엔드 · 데이터 분석 중심의 프로젝트와 경험을 공유합니다.

 Contact Me

Data analysis/데이터 분석 및 시각화

[데이터 분석 및 시각화] 7. 이변량분석 - (범주형 -> 범주형)

endingo 2025. 4. 5. 12:34

★ 범주형 vs 범주형

- 교차표: crosstab()
- 시각화: 100% stacked Bar, Mosaic Plot
- 수치화: 카이제곱 검정

1. 교차표

범주형 vs 범주형을 비교하기 위해서는 교차표를 먼저 만들어야된다.

- Pandas 사용
crosstab()

Sex(범주형) -> Survived(범주형) 교차표



정훈이의 공부일지



Survived	0	1
Sex		
female	81	233
male	468	109

Embarked(범주형) -> Survived(범주형) 교차표

```
pd.crosstab(titanic['Embarked'], titanic['Survived'])
```

Survived	0	1
Embarked		
C	75	93
Q	47	30
S	427	219

※ 교차표의 속성값(normalize)

'index': 각 행의 상대적인 비율(각 행의 합이 1)

'columns': 각 열의 상대적인 비율(각 열의 합이 1)

'all': 각 셀의 상대적인 비율(전체 합 1)

```
pd.crosstab(titanic['Embarked'], titanic['Survived'], normalize='columns')
```

```
pd.crosstab(titanic['Embarked'], titanic['Survived'], normalize='index')
```

```
pd.crosstab(titanic['Embarked'], titanic['Survived'], normalize='all')
```

normalize='columns'

Survived	0	1
Embarked		
C	0.136612	0.271930
Q	0.085610	0.087719
S	0.777778	0.640351

normalize='index'

Survived	0	1
Embarked		
C	0.446429	0.553571
Q	0.610390	0.389610
S	0.660991	0.339009

normalize='all'

Survived	0	1
Embarked		
C	0.084175	0.104377
Q	0.052750	0.033670
S	0.479237	0.245791

통상적으로 'index' 속성을 많이 사용한다.

2. 시각화



정훈이의 공부일지



1) 100% Stacked Bar

- 범주형 vs 범주형이므로 교차표를 일단 만들기

Pclass(범주형) -> Survived(범주형)

```
table = pd.crosstab(titanic['Pclass'], titanic['Survived'], normalize='index')
table
```

Survived	0	1
Pclass		
1	0.370370	0.629630
2	0.527174	0.472826
3	0.757637	0.242363

Pclass 행의 합이 1이되고

각 객실등급별로 생존자, 사망자의 비율을 나타낼 수 있게되었다.

- 교차표 만들었으니 Stacked Bar로 시각화하기


1 - titanic['Survived'].mean()은 사망자의 평균이다.

```
table.plot(kind='bar', stacked=True)
```

```
plt.axhline(1-titanic['Survived'].mean(), color='r')
```

```
plt.xticks(rotation=0)
```

```
plt.show()
```





정훈이의 공부일지



3: 생존자 < 사망자

사망자의 평균을 봤을 때 1클래스, 2클래스는 평균보다 생존자가 많다는 것을 알 수 있다.

2) Mosaic Plot


100 % Stacked Bar는 비율만 비교하므로 양에 대한 비교는 할 수 없다.

이를 극복하기위하여 Mosaic Plot이 나왔다.

- `tastmodels.graphics.mosaicplot`

`mosaic()`: Mosaic Plot 그리기

```
mosaic(titanic, ['Pclass', 'Survived'])
plt.axhline(1-titanic['Survived'].mean(), color='r')
plt.show()
```



x 축 길이는 객실 등급별 승객 비율을 양적으로 나타낸것

=> 3 > 1 > 2 순으로 많이 탔죠?

y 축 길이는 객실 승객의 사망, 생존 비율을 나타낸것

=> 3은 사망자 수가 많고, 1은 생존자 수가 많고, 2는 비슷하고

왜 x 축이 3, 1, 2 순으로 표시될까? 범주형이기때문에 그냥 표에서 나타난 순으로 표시한것임
정렬하고 싶으면

`sort_values()` 사용

※ `gap`을 통해 영역 간격 조절 가능



정훈이의 공부일지



이렇게 할 경우 Pclass로 먼저 정렬하고 Survived로 정렬

3. 수치화

범주형 vs 범주형 관계를 수치화해 비교할 때는 카이제곱검정을 사용

개념: 기대값과 실제값의 차이가 얼마나 큰지?(이론적으로 나와야할값 vs 실제값)

- scipy.stats 라이브러리 사용

chi2_contingency()

※ 카이제곱통계량(어려움 주의)

$$\chi^2 = \sum_i^N \frac{(Observed_i - Expected_i)^2}{Expected_i}$$

카이제곱통계량은 클수록 기대빈도로부터 실제 값의 차이가 크다는 의미

=> 자유도의 2~3배보다 크면, 차이가 있다고 본다

예를들어 Pclass 범주가 3개, Survived 범주가 2개이면

카이제곱검정은

$(3-1) * (2-1) = 2$

2의 2~3배인 4~6보다 통계량이 크면 차이가 있다고 볼 수 있다.

카이제곱 예시)

기대값과 실제값이 얼마나 차이가 나는지 확인

i. 문제

학년에 따라 급식 선호도가 다를까?

=>

grade, like 둘다 범주형

=>

3학년이 좋아함이 확실히 많지만 인원도 많으니 이걸 수치적으로 확인해봐야된다.

=>

기대값(기대빈도를 확인)

학교 급식



정훈이의 공부일지



2학년	97	87	184
3학년	372	119	491
합계	549	342	891

ii. 기대빈도 계산

만약 학년과 선호도 사이에 차이가 없다면이라는 전제하에 계산을 하는 것

$$E_{ij} = \frac{\text{해당 행의 합} \times \text{해당 열의 합}}{\text{전체 합}}$$

$$E_{11} = \frac{216 \times 549}{891} = 133.09$$

1학년이 좋아함 기대값

iii. 실제값과 기대값의 차이를 구한다.

$$(80 - 133.0909)$$

우리가 계산한 기대빈도: 133

실제값: 80

iv. 차이가 얼마나 큰지 카이제곱 통계량을 구한다.

왜 제곱이냐? 어떤 값은 양수, 어떤 값은 음수여서 차이를 더하면 서로 상쇄될 수 있다.

그러면 차이의 크기가 왜곡될 수 있다.

왜 차이를 기대값으로 나누냐? 기대값이 작은 값과 큰 값이 있을 때 같은 차이를 똑같이 평가 할 수 없으므로 비율을 똑같이 만들어줘야함 => 상대적인 차이를 반영해야됨

이를 반복해서 다 더하기

$$\chi^2 = \frac{(80 - 133.0909)^2}{133.0909} + \frac{(97 - 113.3737)^2}{113.3737} + \frac{(372 - 302.5354)^2}{302.5354} + \frac{(136 - 82.90909)^2}{82.90909} + \frac{(87 - 70.62626)^2}{70.62626} + \frac{(119 - 188.4646)^2}{188.4646} = 102.889$$



정훈이의 공부일지



-실습-

1) 범주형 vs 범주형이므로 교차표 만들기

```
table = pd.crosstab(titanic['Pclass'], titanic['Survived'])
table
```

Survived	0	1
Pclass		
1	80	136
2	97	87
3	372	119

2) 카이제곱 검정 수행

```
chi2_contingency(table)
```

```
result = spst.chi2_contingency(table)
print('* 카이제곱통계량:', result[0])
print('* p-value:', result[1])
print('* 기대빈도:\n', result[3])
```

Survived	0	1
Pclass		
1	80	136
2	97	87
3	372	119

카이제곱은 자동으로 나오니 어려워하지말자

```
result = spst.chi2_contingency(table)
print('* 카이제곱통계량:', result[0])
print('* p-value:', result[1])
print('* 기대빈도:\n', result[3])
```



정훈이의 공부일지



```
[[133.09090909 82.90909091]  
[113.37373737 70.62626263]  
[302.53535354 188.46464646]]
```

카이제곱통계량: 기대빈도와 실제 빈도의 차이가 크다!!

p-value: 대립가설 채택 기대빈도와 실제빈도가 유의미하게 다름

기대빈도: 우리가 계산한 기대값

결론: 객실 등급별로 생존자수가 엄청나게 차이난다!!

공감

구독하기

[Data analysis](#) > [데이터 분석 및 시각화](#) 카테고리의 다른 글

[\[데이터 분석 및 시각화\] 8. 이변량분석 - \(수치형 -> ... \(0\)](#)

[\[데이터 분석 및 시각화\] 6. 이변량분석 - \(범주형 -> ... \(0\)](#)

[\[데이터 분석 및 시각화\] 5. 이변량분석 - \(수치형 -> ... \(0\)](#)

[\[데이터 분석 및 시각화\] 4. 단변량 분석 - 범주형 \(0\)](#)

[\[데이터 분석 및 시각화\] 2. 시각화\(Seaborn 활용\) \(0\)](#)

정훈이의 공부일지

개발하면서 겪는 시행착오와 배움을 기록합니다. 백엔드, AI, 데이터 분석, 프로젝트 경험 중심으로 운영 중입니다. 공부하면서 얻은 인사이트를 함께 나누고 싶어요!

구독하기

댓글 0



이름

비밀번호



정훈이의 공부일지



등록

공지사항

최근에 올라온 글

최근에 달린 댓글

Total

- [딥러닝] 3. 회귀 모델링
- [딥러닝] 2. Pytorch
- [딥러닝] 1. 딥러닝 개요
- [데이터 분석 및 시각화] 8. 이번...

93

Today	28
Yesterday	25

링크

TAG

[more](#)

« 2025/04 »

글 보관함

- git
- github

일	월	화	수	목	금	토
		1	2	3	4	5
6	7	8	9	10	11	12
13	14	15	16	17	18	19
20	21	22	23	24	25	26
27	28	29	30			

- 2025/04 (13)
- 2025/03 (7)

Blog is powered by Tistory / Designed by Tistory



이정훈 개발자

AI와 백엔드, 데이터 분석을 좋아하는 개발자입니다.
다양한 문제 해결과 창의적인 개발을 추구합니다.
[이메일 보내기](#)