



endingo

정훈이의 공부일지

CATEGORY



👋 안녕하세요, AI 개발자 이정훈입니다

AI · 백엔드 · 데이터 분석 중심의 프로젝트와 경험을 공유합니다.

 Contact Me

Data science/자연어처리

[자연어처리] 2. 임베딩

endingo 2025. 4. 12. 20:07

- 벡터: 여러 개의 숫자가 모여서 하나의 개념을 표현하는 단위
- 임베딩: 텍스트는 컴퓨터가 이해 x => 토큰을 수치화된 벡터로 변환하는 과정

1. 빈도 기반 벡터화

1) 공동작업

- 토큰화

Kiwi()

kiwi.tokenize(text)

kiwi = Kiwi()

Kiwi 토큰화(명사, 동사, 형용사만 추출)

```
def tokenize_kiwi(text):
```

```
    tokens = kiwi.tokenize(text)
```



정훈이의 공부일지



토큰을 문자열로 재조합하고 싶을 때

```
tokenized_docs = [" ".join(tokenize_kiwi(doc)) for doc in documents] # 각 토큰은 ' '로 구분
print(tokenized_docs)
```

2) BOW: 빈도기반 벡터화

개념: 각 문장에서 등장하는 단어들을 하나의 주머니에 담고, 각 단어의 등장 횟수를 카운트한 후 이를 문장에 대한 벡터로 사용

한계: 단어의 순서, 원래의 의미, 맥락은 파악 할 수 없다.

- BOW 벡터화

CountVectorizer()

bow_vectorizer.fit_transform(tokenized_docs): 벡터화

bow_vectorizer.vocabulary_: 벡터화 결과 출력

pd.DataFrame: 데이터프레임 출력

기본값은 글자 2개 이상만 카운트

bow_vectorizer = CountVectorizer()

X = bow_vectorizer.fit_transform(tokenized_docs)

결과 출력

print("Vocab", bow_vectorizer.vocabulary_)

DataFrame 변환 및 출력 (BOW)

bow_df = pd.DataFrame(X.toarray(), columns=bow_vectorizer.get_feature_names_out())

display(bow_df)

Vocab {'영화': 7, '재미있': 8, '감동': 0, '배우': 1, '연기': 5, '출품': 11, '지루': 10, '최고': 9, '시간': 4, '아깝': 3, '스토리': 2, '감독': 0}												
	감독	배우	스토리	시간	아깝	연기	연출	영화	재미있	지루	최고	출품
0	1	1	0	0	0	1	0	1	1	0	0	1
1	0	0	0	1	1	0	0	0	0	1	0	0
2	0	1	0	0	0	1	0	0	1	0	0	0
3	1	0	1	0	0	0	1	2	0	0	1	2
4	0	1	1	0	0	1	0	1	0	0	0	0

3) TF-IDF 벡터화

BOW: 자주 등장하는 단어가 영향을 주고, 단어의 중요도를 반영하지 않는다.

TF-IDF: 등장횟수 대신 단어의 중요도를 반영

TF: 얼마나 한 문서에 자주등장하는지

IDF: 특정 단어가 전체문서에서 얼마나 희귀한지

- 코드

TfidfVectorizer(): 벡터화

tfidf_vectorizer.fit_transform(tokenized_docs): 벡터화



정훈이의 공부일지



기본값은 글자 2개 이상만 카운트

```
tfidf_vectorizer = TfidfVectorizer()
X = tfidf_vectorizer.fit_transform(tokenized_docs)
```

단어 사전 출력

```
print("Vocabulary (단어 사전):", tfidf_vectorizer.vocabulary_)
```

벡터화 결과

```
tfidf_df = pd.DataFrame(X.toarray().round(3), columns=tfidf_vectorizer.get_feature_names_out())
tfidf_df
```

Vocabulary (단어 사전): {'영화': 7, '재미있': 8, '감동': 0, '배우': 1, '연기': 9, '감독': 2, '시나리오': 3, '제작': 4, '출연': 5, '주제': 6, '배경': 10, '장르': 11}

	감독	배우	감독	시간	아깝	연기	연출	영화	재미있	지루	최고	출연
0	0.444	0.369	0.000	0.000	0.000	0.369	0.00	0.369	0.444	0.000	0.00	0.444
1	0.000	0.000	0.000	0.577	0.577	0.000	0.00	0.000	0.000	0.577	0.00	0.000
2	0.000	0.538	0.000	0.000	0.000	0.538	0.00	0.000	0.648	0.000	0.00	0.000
3	0.291	0.000	0.291	0.000	0.000	0.000	0.36	0.483	0.000	0.000	0.36	0.588
4	0.000	0.474	0.571	0.000	0.000	0.474	0.00	0.474	0.000	0.000	0.00	0.000

2. 분포 가설 방식: Word2Vec

- 비슷한 문맥에서 자주 등장하는 단어들이 유사한 벡터를 가지도록 학습하는 임베딩 기법

- 빈도 기반 방식과 비슷하게

데이터 전처리: 불용어처리, 토큰화를 해준다

Word2Vec 학습 두 가지 방법:

CBOW: 주변단어 -> 중심 단어 예측

Skip-gram: 중심단어 -> 주변 단어 예측

1) cbow 학습

```
Word2Vec(sentences=token_data, vector_size=100, window=5, min_count=5, workers=4, sg=0)
```

```
model_cbow = Word2Vec(sentences=token_data, vector_size=100, window=5, min_count=5, workers=4,
sg=0) # CBOW
```

model_cbow.wv.most_similar("한석규", topn=20)): Word2Vec 모델을 사용해서 '한석규와' 가장 비슷한 단어 20개를 출력

```
print(model_cbow.wv.most_similar("한석규", topn=20))
```



정훈이의 공부일지



model_cbow.wv['한석규']: 한석규라는 단어의 벡터 표현을 가져오는 코드

한석규 벡터

```
model_cbow.wv['한석규']
```

코사인 유사도

```
model_cbow.wv.similarity('한석규', '안성기')
```

코사인 유사도

```
model_cbow.wv.similarity('한석규', '안성기')
```

```
0.9033068
```

2) skip_gram 학습

```
model_skip = Word2Vect()
```

```
model_skip = Word2Vec(sentences=token_data, vector_size=100, window=5, min_count=5, workers=4, sg=1)
```

skip_gram

- model_skip.wv.most_similar("한석규")

Word2Vec 모델을 사용해서 '한석규와' 가장 비슷한 단어 20개를 출력

```
print(model_skip.wv.most_similar("한석규"))
```

```
[('송강호', 0.8843399286270142), ('안성기', 0.8807603716850281), ('설경구', 0.87
```

한석규 벡터

```
model_skip.wv['한석규']
```

- 코사인 유사도 검사: model_skip.wv.similarity('한석규', '안성기')

코사인 유사도

```
model_skip.wv.similarity('한석규', '안성기')
```

```
0.8786766
```

공감

구독하기



정훈이의 공부일지



정훈이의 공부일지

개발하면서 겪는 시행착오와 배움을 기록합니다. 백엔드, AI, 데이터 분석, 프로젝트 경험 중심으로 운영 중입니다. 공부하면서 얻은 인사이트를 함께 나누고 싶어요!

구독하기

댓글 0

이름

비밀번호

로그인 댓글만 허용한 블로그입니다

등록

공지사항

최근에 올라온 글

- [자연어처리] 3. RNN 개념 이해
- [자연어처리] 2. 임베딩
- [자연어 처리] 1. 토큰화
- [이미지처리] 5. YOLO 모델

최근에 달린 댓글

덕분에 좋은 정보 얻어 갑니다 ! ...

Total

218

Today	1
Yesterday	1

링크

TAG

- git
- github

more

«		2025/04					»	
일	월	화	수	목	금	토		
		1	2	3	4	5		
6	7	8	9	10	11	12		
13	14	15	16	17	18	19		
20	21	22	23	24	25	26		
27	28	29	30					

글 보관함

- 2025/04 (27)
- 2025/03 (7)



정훈이의 공부일지



AI와 엑셀, 데이터 분석을 좋아하는 개발자입니다.

다양한 문제 해결과 창의적인 개발을 추구합니다.

 이메일 보내기